

REGRESIÓN LOGÍSTICA

ÍNDICE

11.0. Conceptos generales.....	3
11.1. El modelo logístico	4
11.2. Cociente de verosimilitudes.....	4
11.3. Variables dummy	6
11.4. Ajuste del modelo.....	6
11.4.1. Calidad del ajuste	6
11.4.2. Recomendaciones generales.....	8
11.5. Manejo del módulo	8
11.5.1. Manejo básico.....	8
11.5.2. Datos tabulados	8
11.5.3. Opciones adicionales.....	9
11.5.3.1. Validación	9
11.5.3.2. Predicción.....	10
11.6. Ejemplos.....	13
Bibliografía	33
Anexo 1: Novedades del módulo de regresión logística	34
Anexo 2: Fórmulas del módulo de regresión logística.....	35

11.0. Conceptos generales

Entre los propósitos de muchas investigaciones epidemiológicas se halla el establecimiento de las leyes que rigen el desenvolvimiento de las enfermedades. El examen se realiza típicamente en un marco complejo, donde la coexistencia de factores mutuamente relacionados determina el comportamiento de otros. Para sondear o incluso desentrañar la naturaleza de tales relaciones, el investigador puede auxiliarse, entre otras alternativas, del análisis de regresión. La *regresión logística* (RL) es la variante de la regresión que corresponde al caso en que se valora la contribución de diferentes factores en la ocurrencia de un evento simple.

En general, la RL es adecuada cuando la variable de respuesta (llamémosle Y en lo sucesivo) es politómica (admite varias categorías de respuesta, tales como MEJORA MUCHO, MEJORA, SE MANTIENE IGUAL, EMPEORA, EMPEORA MUCHO); pero es especialmente útil cuando solo hay dos posibles desenlaces (cuando la variable de respuesta es dicotómica), que es el caso más común.

Es lo que ocurre, por ejemplo, en las siguientes situaciones: el paciente hospitalizado muere o sobrevive durante las primeras 48 horas de su ingreso, el organismo acepta o no un órgano trasplantado, se produjo o no un intento suicida antes de los 60 años, etc.. En cada uno de estos ejemplos puede desearse la construcción de un modelo que exprese la probabilidad de ocurrencia del evento de que se trate en función de un conjunto de variables independientes. La variable Y se codifica de cierta manera, por ejemplo como 1 si se produce cierto desenlace, y como 0 en caso opuesto, de modo que la RL expresa $P(Y=1)$ en función de ciertas variables relevantes a los efectos del problema que se haya planteado.

La finalidad con que se construye ese modelo no es única; básicamente, hay tres propósitos posibles: que se trate de una mera contribución a la descripción de cierto proceso, que se aplique en la búsqueda de explicaciones causales o para la construcción de un modelo para la predicción.

La RL es una de las técnicas estadístico-inferenciales más empleadas en la producción científica contemporánea. Surge en la década del 60 con la aparición del trabajo de Cornfield, Gordon y Smith [1] sobre el riesgo de padecer una enfermedad coronaria que constituye su primera aplicación práctica trascendente. Su generalización dependía de la solución que se diera al problema de la estimación de los coeficientes. El algoritmo de Walker-Duncan [2] para la obtención de los estimadores de máxima verosimilitud vino a solucionar en parte este problema, pero era de naturaleza tal que el uso de computadoras resultaba imprescindible.

De su amplio y creciente empleo han dado cuenta varias revisiones. Silva, Pérez y Cuellar [3] consignan que ésta fue la técnica estadística más usada entre los 1.045 artículos publicados por *American Journal of Epidemiology* entre 1986 y 1990 (casi 3 de cada 10 trabajos allí publicados). Levy y Stolte [4] llevaron a cabo un estudio para caracterizar la tendencia en el uso de métodos estadísticos surgidos (entre los 60 y los 70) y que, además, hubieran tenido un impacto considerable en el análisis de datos biomédicos; entre ellos figura la regresión logística.

En PUBMED, base de datos que contiene referencias bibliográficas y resúmenes de miles de las connotadas revistas biomédicas de habla inglesa y contiene más de 22 millones de citas, se encontró en junio de 2013 que el crecimiento en el uso de la RL a lo largo de los últimos treinta años ha sido espectacular: los artículos publicados que hacen mención al término *logistic regression* son, para siete años seleccionados, como muestra la Tabla 1:

Tabla 1. Número de artículos de PUBMED que emplearon la expresión “logistic regression” para años seleccionados.

Año	1980	1985	1990	1995	2000	2005	2010
Número de artículos	31	204	800	2.424	4.413	7.949	14.269

Como se ilustra más adelante, una de las razones que confiere especial interés a la regresión logística en el marco epidemiológico es que con ella se pueden “controlar” varias variables potencialmente confusoras (de cualquier naturaleza) a la vez. Este rasgo es especialmente atractivo en el marco observacional, pues en el de los ensayos clínicos, tal control lo ejerce la aleatorización, elemento inaplicable en los estudios de cohorte o de casos y controles. Hasta que el uso de la RL se generalizó (gracias a las computadoras personales), el recurso al que se podía apelar era la realización de análisis estratificados de las asociaciones entre posibles causas y efectos, un procedimiento artesanal y sumamente limitado del que ahora puede prescindirse por entero.

11.1. El modelo logístico

El problema que resuelve la regresión logística es expresar la probabilidad de cierto desenlace ($Y=1$) en función de r variables $X_1, X_2 \dots X_r$ las cuales pueden ser de cualquier naturaleza (continuas, discretas, dicotómicas, ordinales o nominales, aunque en este último caso han de manejarse a través de variables *dummy*, como se explica debajo). Concretamente, el resultado fundamental del programa consiste en hallar los coeficientes $\beta_0, \beta_1 \dots \beta_r$, que mejor se ajustan a la siguiente representación funcional:

$$P(Y = 1) = \frac{1}{1 + \exp(-\beta_0 - \beta_1 X_1 - \dots - \beta_r X_r)}$$

donde $\exp(.)$ representa la función exponencial.

11.2. Cociente de verosimilitudes

Para que un modelo sea considerado adecuado, éste debe atribuir una alta probabilidad de que se produzca el desenlace de interés a aquellos sujetos para los cuales, efectivamente, se tiene $Y=1$ y viceversa. Por tanto, una medida razonable para valorar el grado en que el modelo arroja resultados coherentes con los datos usados para su construcción sería el producto de todas las probabilidades (predichas por el modelo) de que los n sujetos de la muestra empleada para su construcción tengan la condición que realmente tienen. Si se llama p_i a la probabilidad estimada por el modelo de que el i -ésimo sujeto tenga cierta condición, y tenemos que d individuos tienen la condición, se puede computar la expresión siguiente:

$$V = [p_1 p_2 \dots p_d] [(1 - p_{d+1})(1 - p_{d+2}) \dots (1 - p_n)]$$

donde los primeros d factores corresponden a sujetos con la condición y los restantes $n-d$ a los que no la tienen.

La magnitud V –un número siempre mayor que 0– es conocida como la *verosimilitud del modelo*. A un modelo completamente exitoso, el cual atribuya una probabilidad de tener la condición

igual a 1 a cada sujeto que realmente la tenga y de 0 a cada sujeto libre de ella, correspondería una verosimilitud máxima de 1; por el contrario, un modelo deficiente tendría una verosimilitud pequeña, cercana a 0. En consecuencia, la proximidad de la verosimilitud a 1 expresa cuán eficiente ha sido el ajuste realizado para modelar la realidad [5].

Debido a que la función de verosimilitud mide la plausibilidad de un modelo de regresión logística, no debe sorprender que para valorar su capacidad predictiva sea central la consideración de la verosimilitud; es decir, de la magnitud V antes introducida. Concretamente, se suele emplear la expresión:

$$L = -2 \ln V$$

A esta transformación se le conoce como *lejanía* del modelo (*deviance* en inglés). Nótese que, siendo $V < 1$, su logaritmo siempre será negativo; de modo que la lejanía L siempre será un número positivo. El grado de ajuste de un modelo será mejor cuanto más próxima a 1 es la *verosimilitud* y, en consecuencia, cuanto más se aproxima a cero la *lejanía*.

Siempre que se ajusta un modelo, el algoritmo de la regresión logística computa dos lejanías: la que corresponde propiamente al modelo que se ha ajustado (L), y la que corresponde al “modelo nulo” (L_0) que es aquel en que no se ha incorporado ninguna variable independiente.

La lejanía del modelo nulo es más grande que la de cualquier modelo ampliado. Esto es razonable, debido a que se trata de un modelo mucho menos sofisticado (que no incorpora información alguna de posibles variables “explicativas”) y debe necesariamente tener una incapacidad predictiva mayor. La diferencia entre estas lejanías mide “el aporte” que hacen las variables incorporadas al modelo. Es decir, para valorar dicho aporte se puede calcular el cociente o razón de verosimilitudes:

$$CV = L_0 - L = -2 \ln V_0 + 2 \ln V = -2 \ln(V_0 - V) = -2 \ln\left(\frac{V_0}{V}\right)$$

CV es un estadístico de gran relevancia, ya que tiene una interpretación clara y debido a que se conoce que se distribuye Ji-cuadrado con r grados de libertad, donde r es el número de variables presentes en el modelo ampliado.

En general, esta razón de verosimilitudes es útil para determinar si hay una diferencia significativa entre incluir en el modelo todas las variables y no incluir ninguna; o, dicho de otro modo: RV sirve para valorar si las variables $X_1, X_2 \dots X_r$ tomadas en conjunto, contribuyen efectivamente a “explicar” las modificaciones que se producen en $P(Y=1)$.

También es útil porque permite valorar el aporte atribuible a cierto conjunto de variables adicionadas a las de un primer ajuste. En efecto, si se ajusta un modelo que produce cierto valor CV_1 y se ajusta otro al que se agregaron h variables, el cual produce un cociente CV_2 , entonces $CV_2 - CV_1$ se distribuye Ji-cuadrado con h grados de libertad, lo cual permite evaluar si la adición de las h variables hace un aporte significativo.

11.3. Variables dummy

Las variables explicativas de tipo nominal deben ser incluidas en el modelo señalando que tienen esa condición. Se trata de variables que no son numéricas (v.g. estado civil o raza) o que, aunque los valores que contiene aparezcan como números, son en realidad códigos o se quieren manejar como tales (por ejemplo, si se asigna el valor 1 para indicar que se trata de un sujeto soltero, el valor 2 para un divorciado, etc.). Supongamos que la variable en cuestión tiene k clases o categorías (donde $k \geq 2$). Epidat 4 construye automáticamente $k-1$ variables *dummy* para manejar esta situación.

Brevemente dicho, el sentido de las variables *dummy* es el siguiente: supóngase que cierta variable es nominal (raza, religión profesada, grupo sanguíneo, etc.) y consta de k categorías; se crean entonces $k-1$ variables dicotómicas, que son las llamadas variables *dummy* asociadas a esta variable nominal y que se denotarán por $Z_1, Z_2, \dots, Z_{k-1}$. A cada categoría o clase de la variable nominal le corresponde un conjunto de valores de los Z_i con el cual se identifica dicha clase.

La manera más usual de definir estas $k-1$ variables es la siguiente: si el sujeto pertenece a la primera categoría, entonces las $k-1$ variables *dummy* valen 0: se tiene $Z_1 = Z_2 = \dots = Z_{k-1} = 0$; si el sujeto se halla en la segunda categoría, entonces $Z_1 = 1$ y las restantes valen 0; Z_2 vale 1 solo para aquellos individuos que están en la tercera categoría, en cuyo caso las otras variables asumen el valor 0, y así sucesivamente hasta llegar a la última categoría, para la cual Z_{k-1} es la única que vale 1. Para más detalles, véase Silva [6].

Por ejemplo, si la variable nominal de interés es el grupo sanguíneo, la cual tiene $k = 4$ categorías (sangre tipo A, tipo AB y tipo B y tipo O), entonces se tendrían los siguientes valores de las 3 variables *dummy* para cada grupo sanguíneo:

Variable nominal (grupo sanguíneo)	Z_1	Z_2	Z_3
A	0	0	0
AB	1	0	0
B	0	1	0
O	0	0	1

En cualquier caso, si se ajusta un modelo que incluya una variable nominal con k clases, esta será sustituida por las $k-1$ variables *dummy*, y a cada una de ellas corresponderá su respectivo coeficiente. A estos efectos, Epidat ordenará las categorías alfabéticamente.

11.4. Ajuste del modelo

11.4.1. Calidad del ajuste

Siempre que se quiere obtener un modelo de regresión, de cualquier tipo, una precaución importante a los efectos de sacar conclusiones es la de corroborar que este modelo se ajusta efectivamente a los datos usados. La RL no es una excepción.

Es bien conocido que, en el contexto de la regresión lineal múltiple, se suele emplear el llamado *coeficiente de determinación* (R^2) para cuantificar mediante una única medida, con cotas interpretables, el grado de “explicación de la variabilidad de la variable de respuesta” conseguido con el modelo por parte de las variables independientes. Varias sugerencias se han hecho para obtener algo similar en el marco de la RL. Sin embargo, no hay una opinión

unánime sobre cuál podría ser la mejor. Epidat 4 ha incorporado una, preferida por Mittlböck y Schemper [7] (quienes examinan 12 posibles mediciones) a la que se denomina aquí, análogamente, *coeficiente de determinación*. R^2 es un número que se halla necesariamente entre 0 y 1. Alcanza el valor 1 cuando el vaticinio es perfecto (esto quiere decir, que R^2 alcanzaría el valor máximo solo si el modelo atribuyera probabilidad 1 a aquellos sujetos de la muestra que efectivamente tuvieron el evento, y valores iguales a 0 a quienes no lo tuvieron) y R^2 se aproxima a 0 en la medida que las probabilidades atribuidas por el modelo disten más, respectivamente, de 1 y 0.

Otros indicadores que se han sugerido con la misma finalidad son el *Coeficiente de Cox y Snell* y el *Coeficiente de Nagelkerke*, los cuales son, en cierto sentido, variaciones del primero. Epidat 4 ofrece los tres indicadores como salida regular.

Cabe advertir, no obstante, que estos coeficientes no miden la bondad del ajuste (un concepto diferente al de “variabilidad explicada por el modelo”), la cual debe valorarse a través de las pruebas específicamente diseñadas con ese fin (en particular, la prueba de Hosmer y Lemeshow [8]).

Epidat 4 permite evaluar la calidad del ajuste del modelo estimado mediante dicha prueba. El estadístico que ellos proponen se calcula a través de varios grupos empleando los deciles de las probabilidades predichas por el modelo, y comparando las frecuencias observadas en dichos grupos con las esperadas.

Si bien Epidat 4 realiza una prueba de bondad de ajuste (PBA) formal en esta situación, procede recordar (véase Silva [9], epígrafe 6.6.1) que todos los modelos son imperfectos, aunque muchos de ellos resultan, no obstante, útiles. Consecuentemente, resulta un poco absurdo que se considere útil un modelo por el solo hecho de que no se ha podido demostrar que es imperfecto o considerarlo inútil por el hecho de que tal imperfección se ha puesto de manifiesto. Si la hipótesis nula afirma, como ocurre con las PBA, que los datos siguen cierta distribución, entonces *sensu strictu* dicha hipótesis siempre es falsa; y por lo tanto se rechazará inexorablemente si la muestra es suficientemente grande. A diferencia de lo que ocurre con otras pruebas de hipótesis, en el caso de las PBA, el rechazo de la hipótesis nula no es el desenlace deseado. De tal suerte, la mejor manera de conseguir lo que se desea sería adoptar la absurda medida cautelar de no tomar una muestra demasiado grande. Y viceversa, con una muestra suficientemente grande, es altamente probable que consigamos rechazar la hipótesis (aunque este es un problema presente en todas las pruebas de significación). Sintetizando, el empleo de un test formal como el de Hosmer-Lemeshow, es cuestionable. Algunos autores sugieren simplemente inspeccionar de manera informal los valores esperados y los observados y, si las diferencias no son muy notables, admitir que el modelo es adecuado.

En los modelos múltiples puede ser interesante incorporar la interacción entre dos variables predictoras. Esto procede cuando se sospecha o se sabe que la influencia de una variable sobre la respuesta puede ser diferente en función de los valores que tome otra variable también incluida en el modelo. Epidat 4 tiene la limitación de no contemplar la posibilidad de definir interacciones de forma automática, pero esto se puede conseguir por parte del usuario definiendo previamente el producto de las dos variables cuya interacción se desea incluir en el modelo como una variable predictora más. Véase Ejemplo 1. Naturalmente, esta idea puede extenderse a más variables; podrían incorporarse términos que involucren a tres o más de ellas, pero esto es sumamente inusual.

11.4.2. Recomendaciones generales

- Las variables explicativas deben tener una relación monótona con la probabilidad del evento que se estudia. Vale decir, cuando el valor de una variable independiente crece, la probabilidad del desenlace ha de aumentar o de disminuir (es decir, no ha de pasar de una tendencia a la opuesta en algún punto del recorrido de la variable independiente).
- Las variables independientes involucradas en el modelo no deben estar muy correlacionadas entre sí. Si la correlación entre dos variables es alta, entonces los resultados de la RL son poco confiables. Concretamente, los errores estándares se incrementan indebidamente y puede ocurrir, incluso, que el proceso iterativo para la estimación no converja.
- Debe recordarse que el conjunto de variables dummy constituye un todo indisoluble con el cual se suple a una variable nominal. Cualquier decisión que se adopte o valoración que se haga concierne al conjunto íntegro (por ejemplo, si una de las variables dummy es significativa, entonces toda la variable nominal lo es).
- Es muy importante distinguir entre un contexto explicativo y uno predictivo. Debe tenerse en cuenta, en este caso, que una variable puede tener valor predictivo aunque no sea parte del mecanismo causal que produce el fenómeno en estudio.
- En lo posible ha de procurarse que haya en la base al menos 10 sujetos con cada una de las respuestas posibles para la variable independiente.

11.5. Manejo del módulo

11.5.1. Manejo básico

La entrada de la información está conformada por una matriz con n filas (tamaño de la muestra) y $r+1$ columnas. Una de ellas ha de contener los datos correspondientes a una *variable dependiente* (o *de respuesta*) dicotómica. Las restantes r columnas recogen la información para respectivas variables independientes (también llamadas “de entrada”, “explicativas” o “predictoras” dependiendo del contexto). El usuario ha de indicar, para cada una de estas últimas si han de tratarse como numéricas o como categóricas; en este último caso, Epidat 4 las manejará a través de la construcción de variables dummy. Las que estén en el primer caso no pueden contener valores que no sean números. Las dicotómicas, naturalmente, son un caso particular de las categóricas (politómicas con dos categorías).

Ya en ese punto, el programa puede proceder a producir el modelo estimado. Como en el resto de Epidat 4, el usuario puede definir un filtro para trabajar con un subconjunto de la muestra definido por las condiciones que imponga, basadas en restricciones para las variables que contenga el archivo que fue proveído.

11.5.2. Datos tabulados

Ocasionalmente, algunos elementos de la muestra contienen exactamente la misma información (un mismo perfil de entrada y un mismo desenlace). Dicho de otro modo, no necesariamente todas las filas de la matriz tienen que ser diferentes. En tal caso, la información de entrada en el programa puede colocarse compactada (tabulada). Para ello debe crearse una variable numérica (que solo admitirá números enteros mayores que 0) que contenga la frecuencia de cada una de las filas diferentes. El usuario ha de marcar la opción

“Tabla de frecuencias” y declarar luego cuál es la variable que contiene las frecuencias (véanse Ejemplos 2 y 3).

11.5.3. Opciones adicionales

Adicionalmente, el usuario puede solicitar que Epidat 4 realice un test de bondad de ajuste y que calcule (y exhiba) la curva ROC asociada.

El usuario tiene dos opciones adicionales:

- a) Pedir que se realice una validación del modelo.
- b) Aplicar el modelo a un conjunto de perfiles para las variables de entrada

Estas dos opciones se explican a continuación.

11.5.3.1. Validación

Como es bien conocido, los modelos nunca constituyen una finalidad en sí misma. Todo modelo procura representar una realidad general, usando para ello información específica que proviene de ella. Para que su aplicación sea fructuosa en otro contexto, sin embargo, el modelo debe ser validado con datos procedentes de ese otro contexto. El acto de corroborar que tiene este mérito (o sea, que hace las predicciones que se supone que hace) se conoce como “validación” del modelo. Para ello se procede en esencia del modo siguiente:

- a) Se construye el modelo usando una Muestra1 de tamaño n_1 .
- b) Se busca una Muestra2, independiente de la primera, de tamaño n_2 , de la que tenemos toda la información (tanto los datos “de entrada” $X_1, X_2 \dots X_r$, como el valor de Y para cada uno de sus elementos).
- c) Se aplica el modelo mencionado en a) a cada vector $X_1, X_2 \dots X_r$ de la Muestra2 y se obtienen n_2 valores de $\hat{P}_i$.
- d) Se valora el grado en que los n_2 valores de $\hat{P}_i$ obtenidos “se parecen” a los respectivos valores de Y .

Nota: Ocasionalmente se inicia el proceso con una muestra de tamaño $n = n_1 + n_2$. La Muestra1 resulta de una subselección simple aleatoria de tamaño n_1 tomada de la muestra inicial, y la validación se realiza usando la submuestra complementaria. Si la validación es exitosa, entonces suele conformarse el modelo definitivo usando la muestra total. Tal procedimiento, sin embargo, puede ser en cierta medida objetado, pues, aunque la validación no se hace con la propia muestra creada para la confección del modelo, cabe esperar que el proceso sea favorecido por el hecho de que ambas muestras serán “parecidas”.

En cualquier caso, para realizar la validación ha de proveerse una nueva base de datos. El programa aplica el modelo que se acaba de construir a cada uno de los sujetos de dicha base. Con los verdaderos desenlaces acaecidos a ellos y con las estimaciones resultantes de la aplicación mencionada, se aplica la prueba de bondad de ajuste de Hosmer y Lemeshow y luego se estima el número esperado de casos con la condición mediante la suma de las probabilidades obtenidas. La comparación de los valores esperados bajo el modelo que se valida y los resultados objetivamente producidos, tanto en un caso como en el otro, permite conformar un juicio sobre la validez del modelo.

Nota cautelar: Cabe advertir que la segunda base de datos tiene que contener todas las variables empleadas en la elaboración inicial del modelo que se quiere validar. Por otra parte, puede ocurrir lo siguiente: en la primera base hay una variable declarada nominal y en la segunda también comparece dicha variable, pero en esta última aparece al menos un caso para el cual dicha variable adopta cierto valor que no estaba presente en ninguno de los casos incluidos en la base original (por ejemplo, en la primera se tiene el estado civil y los sujetos que contiene son casados, solteros o divorciados, pero no hay ningún viudo; mientras que en la segunda base si aparece al menos un viudo). En esa situación, al realizarse la validación, Epidat elimina de la segunda base todos los casos donde se presente esta singularidad (en el ejemplo, prescindirá de las filas en las que se declare que el sujeto es viudo).

11.5.3.2. Predicción

11.5.3.2.0. Conceptos generales

Una vez construido el modelo, se puede solicitar a Epidat 4 la estimación de probabilidades correspondientes a un conjunto dado de perfiles de entrada. El usuario ha de proveer una matriz de datos. Todas las variables independientes presentes en el modelo ajustado han de figurar en esta matriz. Para cada uno de los perfiles incluidos, Epidat 4 no solo realiza una estimación puntual sino que computa un intervalo de confianza, empleando para ello la técnica bootstrap.

Típicamente, en la segunda matriz se incluyen algunos perfiles que el usuario considera que son teórica o prácticamente relevantes (Véanse ejemplos 1, 2 y 4). Sin embargo, la dimensión de la matriz introducida para la predicción no tiene restricciones. Si el número de filas (perfiles) supera a 20, Epidat no presentará las estimaciones en la pantalla de salida sino que, directamente, solo las enviará a un archivo para que sea salvado por el usuario.

Nota cautelar: Procede advertir que la segunda base de datos ha de contener todas las variables empleadas para la construcción inicial del modelo. Además, puede ocurrir que en la primera base haya alguna variable declarada como categórica, también presente en la segunda, pero con la singularidad de que en esta última aparece al menos un caso para el cual dicha variable tiene una condición no presente en ninguno de los casos incluidos en la base inicial (por ejemplo, en la primera se tiene que en la variable RELIGIÓN aparecen sujetos católicos, protestantes o musulmanes, pero no hay ningún sujeto ateo; mientras que en la segunda base si aparece al menos un ateo). En esa situación, al realizarse la predicción Epidat elimina de la segunda base todos los casos donde se presente esta singularidad (es decir, todas las filas correspondientes a individuos ateos).

11.5.3.2.1. Teorema de Bayes y predicción

Supongamos que se tiene una probabilidad P a priori de que determinada condición morbosa E esté presente en un sujeto (llamaremos $O=1-P$ a su complemento, la probabilidad de que esté sano, $\bar{E}$), y que se cuenta con una prueba diagnóstica T que puede arrojar dos resultados (positivo $T+$ y negativo $T-$).

Mediante el Teorema de Bayes se puede computar cuál es la probabilidad a posteriori de estar enfermo en cada uno de los dos casos. Para ello han de conocerse dos parámetros inherentes a la prueba: la sensibilidad y la especificidad. El primero mide la capacidad de la

prueba para detectar a un sujeto enfermo; expresa cuán "sensible" es la prueba ante la presencia de la enfermedad y viene definido por la probabilidad condicional $\alpha = P(T+ | E)$. La segunda se define a través de la probabilidad condicional $\beta = P(T- | \bar{E})$, la cual mide cuán específica es la prueba diagnóstica en el sentido siguiente: cuanto mayor sea β , menor será su complemento $P(T+ | \bar{E})$; o sea, menor es la probabilidad de que declare como enfermos a sujetos que no sufren esta enfermedad.

Lo que resulta deseable en este contexto es que, si el resultado de la prueba es positivo, la probabilidad de que el sujeto esté efectivamente enfermo sea muy alta y, análogamente, que sea elevada la de que el individuo esté sano, supuesto que la prueba arroja un resultado negativo. En términos formales, lo ideal es que sean muy altos los valores $P(E | T+)$ y $P(\bar{E} | T-)$ que son probabilidades condicionales a las que se les denomina *valores predictivos de la prueba*.

Aplicando el Teorema de Bayes se obtienen entonces el valor predictivo positivo y el valor predictivo negativo mediante las siguientes fórmulas, respectivamente:

$$P(E | T+) = \frac{P \alpha}{P \alpha + O(1 - \beta)} \text{ y } P(\bar{E} | T-) = \frac{O \beta}{O \beta + P(1 - \alpha)}$$

Cuando el valor P se obtiene a través de la RL, se dan las condiciones para estimar por este conducto con más precisión la probabilidad de que el sujeto esté sano y la de que esté enfermo, combinando este resultado con lo que pudiera arrojar una prueba diagnóstica adicional (véase Ejemplo 4). Cuando se trabaja con la predicción siempre se agregan 3 columnas (el valor estimado de P y sus respectivos límites de confianza), pero si se marca que sí se quieren valores predictivos (el supuesto por defecto es que no), entonces se agregarían 9 columnas en total debido a que se estiman 3 parámetros y para cada uno de ellos, los dos límites del intervalo de confianza.

11.5.3.2.2. Predicción con muestras no representativas

Al emplear la RL, como ocurre en rigor con cualquier otra técnica estadística, se debe ser cauteloso. Si bien el modelo no tiene restricciones en cuanto a la distribución de las variables independientes (eso es lo que hace posible, por cierto, que se pueda emplear con datos tabulados; véase Sección 11.5.2), para que el análisis tenga sentido pleno, debe aplicarse con fines predictivos solo en los estudios prospectivos, cuando se tenga certeza de que los acontecimientos registrados por las variables independientes ocurrieron *antes* que los desenlaces. Análogamente, se sobreentiende que la muestra que ha sido objeto del seguimiento en este tipo de estudios es representativa de la población de procedencia.

Hay en principio dos situaciones en que el modelo obtenido no se puede aplicar directamente para hacer cálculos de la probabilidad (es decir, para hacer la predicción) correspondiente a un perfil dado. En ambos casos debido a que la muestra empleada no se puede considerar representativa de la población.

La primera concierne a los estudios retrospectivos (estudios de casos y controles). Típicamente, el número de casos (para los cuales $Y=1$) es mucho mayor que el de casos con ese desenlace en la población. Por ejemplo, puede ocurrir que la tasa de prevalencia o incidencia de dicho problema sea, digamos, igual al 4% del total, mientras que para hacer el estudio se han tomado tantos casos como controles (es decir, la fracción en la muestra es de un 50%).

La segunda situación se da cuando el modelo predictivo se ha obtenido en determinado contexto (cierto país o cierto hospital) y luego se quiere aplicar a otro contexto, donde las condiciones (por ejemplo, tecnológicas, ambientales o demográficas) son otras.

En ambos casos, es necesario hacer correcciones que permitan emplear el modelo originalmente obtenido. La situación típica es la siguiente. Llamemos Modelo 1 al que se obtuvo originalmente y Modelo 2 al que se debe aplicar. Este segundo modelo hace uso de las estimaciones que el primero arrojó para los r coeficientes correspondientes a las variables incluidas: $\beta_1, \beta_2 \dots \beta_r$ pero debe “corregir” el valor del coeficiente independiente β_0 .

Concretamente, habría que obtener un coeficiente β_0^* mediante la fórmula:

$$\beta_0^* = \beta_0 - \ln \left[f_1 \left(\frac{1-f_2}{f_2} \right) \right] \text{ donde } f_1 \text{ es la tasa en el entorno donde se hizo el estudio y } f_2 \text{ es la tasa}$$

de aquel en el cual se quiere aplicar. Por ejemplo, si se ha hecho un ajuste para la probabilidad de que un sujeto quemado muera antes de egresar del hospital (véase ejemplo 1) en un enclave donde el 15% de los pacientes mueren, y se quiere aplicar en otro donde esto ocurre con el 35% de los pacientes (quizás debido a que en el primero se tienen recursos terapéuticos mucho más avanzados), y si el coeficiente independiente resultante del ajuste fue $\beta_0 = -9,488$; entonces, para aplicarlo en el segundo enclave hay que emplear $\beta_0^* = -9,488 - \ln(0,15 \times 0,65 / 0,35) = -9,008$.

Si el estudio se realizó usando el método de casos y controles donde se tomaron tantos casos como controles, se tendría $f_1 = 0,5$. Para calcular probabilidades en la población donde, supongamos que muere realmente el 6% de los ingresados, entonces habría que considerar $f_2 = 0,15$ y el coeficiente independiente a emplear sería: $\beta_0^* = -9,488 - \ln(0,5 \times 0,94 / 0,06) = -11,546$.

11.5.3.2.3. Curva ROC

En un contexto predictivo, con frecuencia se desea seleccionar el mejor modelo entre todos los posibles. El área bajo la curva ROC puede ayudar, por ser una vía para comparar diferentes modelos, y por ofrecer una medida de las respectivas capacidades predictivas que ostentan. Cuanto mayor sea esa área, más eficiente es el modelo. Para un modelo concreto, la curva ROC se construye del modo que se expone a continuación.

Si fijamos un “punto de corte”, un valor cualquiera entre 0 y 1, podemos clasificar las n probabilidades predichas por el modelo en una tabla de 2×2 : por una parte se tienen las que están por debajo o por arriba de dicho punto y, por otra, las que corresponden a sujetos que presentan el evento (respuesta $Y=1$) y las que corresponden a quienes no lo presentan (respuesta $Y=0$).

Desde esta perspectiva, puede considerarse el modelo de regresión logística como un medio para definir una prueba diagnóstica cuantitativa. Así podemos entenderlo si se fija un umbral para hacer el diagnóstico (por ejemplo, diagnosticar enfermo a un sujeto si $P(Y=1) > 0,8$ y declararlo sano en caso contrario) en una situación en que se conozcan los verdaderos desenlaces. Usando la tabla antedicha, es posible calcular la *sensibilidad* (porcentaje de sujetos con la condición que son clasificados correctamente por el modelo) y la *especificidad* (porcentaje de sujetos sin ella que son clasificados como tales por el modelo).

Ahora, si se toman varios puntos de corte o umbrales sucesivamente, se tendrán respectivas parejas de valores de sensibilidad y especificidad. La curva ROC se obtiene representando, en un cuadrado de lado 1, los valores de **1-especificidad** en el eje de abscisas frente a **sensibilidad** en el de las ordenadas para todos los puntos de corte considerados.

Epidat 4 construye la curva usando cada uno de los valores predichos como puntos de corte, de modo que se tendrán tantos puntos en la curva como tamaño tenga la muestra. La curva empieza en el punto (0,0), que corresponde al punto de corte 1, y termina en (1,1) que se obtiene al considerar el 0 como punto de corte. Si el modelo tiene capacidad predictiva nula,

la curva coincide con la diagonal principal del cuadrado, y el área bajo la curva toma su valor mínimo de 0,5. Por el contrario, un modelo perfecto tiene una curva ROC con área 1.

Además de la estimación del área bajo la curva ROC, Epidat 4 ofrece un intervalo de confianza para esta estimación.

11.6. Ejemplos

Ejemplo 1: Predicción en un servicio de caumatología

En un servicio hospitalario de quemados se quiere construir un modelo predictivo para la muerte de los pacientes que ingresan. Los especialistas han valorado que las siguientes 6 variables de los pacientes pudieran tener valor predictivo a los efectos de que sobrevivan (egresen vivos) o mueran (fallezcan en el hospital):

- Edad medida en años (E).
- Porcentaje del cuerpo con quemaduras hipodérmicas (Q1).
- Porcentaje del cuerpo con quemaduras epidérmicas (Q2).
- Porcentaje del cuerpo con quemaduras intermedias (Q3).
- Diabetes, dicotómica: 1 o 0 para indicar que la padece o no, respectivamente (DIA).
- Las quemaduras afectan o no la cabeza del paciente: 1 o 0 para indicar si ocurre o no, respectivamente (CAB)

La variable de respuesta se llamará MUERE y puede tomar los valores SI o NO en dependencia de cuál haya sido el estado del paciente al egresar.

Supongamos que se tomaron los últimos 1.000 egresados en dicho servicio para construir el modelo.

El libro en formato Excel nombrado QUEMADOS.XLS contiene cinco hojas. En la primera, llamada MODELO, figuran los perfiles y los desenlaces correspondientes (muerte o no) para los 1.000 individuos. En la hoja MODELO-INT se ha agregado a la anterior una variable para valorar la interacción de otras dos (véase debajo). En VALID se incluyeron los otros 1.000 pacientes (por ejemplo, los 1.000 anteriores a los de la muestra inicial). En la hoja UNIDO se han colocado las dos bases anteriores juntas. En la hoja PRED, finalmente figuran los 8 perfiles concretos siguientes, para los cuales se quieren estimar las probabilidades de muerte:

E	Q1	Q3	Q2	DIA	CAB
20	5	5	5	0	0
30	5	5	5	0	0
30	10	5	5	0	0
30	10	15	5	0	0
30	10	15	20	0	0
30	10	15	20	1	0
30	10	15	20	1	1
60	10	15	20	1	0

Al correr el programa usando la hoja MODELO se obtiene lo siguiente (nótese que en este caso las variables DIA y CAB se pueden incluir como numéricas y como categóricas debido a que en ambos casos sus valores posibles se han codificado como números; los resultados serán los mismos):

Resultados con Epidat 4:

Entrada automática:

Archivo de trabajo: C:\Archivos de programa\Epidat 4\Ejemplos\Regresión logística\QUEMADOS.xls

Tabla: MODELO

Variables:

Variable dependiente: MUERE

Variables independientes (numéricas): EDAD, Q1, Q2, Q3, DIA, CAB

Datos:

Filtro: No

Nivel de confianza: 95,0 %

Codificación de la variable dependiente:

MUERE	Valor
NO	0
SI	1

Resultados:

Estimación:

Frecuencias de la variable dependiente:

Valor	Frecuencia
NO	846
SI	154
Total	1.000

Convergencia de la sucesión de estimadores: Sí

-2 ln Verosimilitud inicial: 859,170

-2 ln Verosimilitud final: 611,018

Cociente de verosimilitudes:

Estadístico R	gl	Valor p
248,152	6	0,000

gl: grados de libertad

Coefficiente de determinación: 0,303

Coefficiente de Cox y Snell: 0,220

Coefficiente de Nagelkerke: 0,381

Coefficientes de cada variable:

Variable	Coefficiente	EE	Wald	Valor p
Constante	-9,488	0,745	-12,729	0,000
EDAD	0,058	0,006	8,947	0,000
Q1	0,226	0,034	6,564	0,000
Q2	0,096	0,030	3,192	0,001
Q3	0,157	0,035	4,463	0,000
DIA	1,223	0,240	5,095	0,000
CAB	1,473	0,221	6,654	0,000

EE: error estándar de los estimadores

Resultados con Epidat 4 (continuación):

Odds Ratio (OR) de cada variable:

Variable	OR	IC (95,0 %)	
EDAD	1,059	1,046	1,073
Q1	1,254	1,172	1,342
Q2	1,101	1,038	1,169
Q3	1,170	1,092	1,253
DIA	3,396	2,122	5,436
CAB	4,362	2,826	6,731


Prueba de bondad de ajuste de Hosmer y Lemeshow:

Estadístico χ^2	gl	Valor p
10,819	8	0,212

gl: grados de libertad

Grupo	MUERE=0		MUERE=1		Total
	Frec. Obs.	Frec. Esp.	Frec. Obs.	Frec. Esp.	
1	98	99,596	2	0,404	100
2	98	98,889	2	1,111	100
3	98	97,832	2	2,168	100
4	98	96,430	2	3,570	100
5	95	94,466	5	5,534	100
6	89	91,362	11	8,638	100
7	88	85,736	12	14,264	100
8	82	78,269	18	21,731	100
9	66	64,648	34	35,352	100
10	34	38,771	66	61,229	100
Total	846	846,000	154	154,000	1.000

Curva ROC:



Área bajo la curva	Error estándar	IC (95,0 %)	
0,855	0,020	0,816	0,894

Supongamos que se quiere valorar el posible efecto de la interacción de la edad con el porcentaje total de quemaduras. En ese caso, hay que crear una variable adicional formada por el producto del valor de la edad y la suma de Q1, Q2 y Q3. La hoja llamada MODELO-INT, que se incluyó en el libro QUEMADOS.XLSX, incluye tal variable (con el nombre EDAD-QT).

Resultados con Epidat 4:

Coefficientes de cada variable:

Variable	Coefficiente	EE	Wald	Valor p
Constante	-10,510	1,773	-5,927	0,000
EDAD	0,076	0,030	2,573	0,010
Q1	0,266	0,070	3,774	0,000
Q2	0,137	0,070	1,954	0,051
Q3	0,195	0,069	2,813	0,005
DIA	1,223	0,240	5,096	0,000
CAB	1,471	0,221	6,664	0,000
EDAD-QT	-0,001	0,001	-0,646	0,518

EE: error estándar de los estimadores

Como se aprecia, si se emplea el test de Wald para valorarlo, la interacción entre EDAD y QT dista de ser significativa ($p=0,518$), de modo que se pensaría en principio que no rige tal interacción. Para la validación, luego de haber corrido el programa con la hoja MODELO, se usa la hoja VALID como segunda matriz. Los resultados obtenidos son los siguientes:

Validación:

Coefficiente de determinación: 0,313

Prueba de bondad de ajuste de Hosmer y Lemeshow:

Estadístico χ^2	gl	Valor p
6,348	8	0,608

gl: grados de libertad

	MUERE=0		MUERE=1		
Grupo	Frec. Obs.	Frec. Esp.	Frec. Obs.	Frec. Esp.	Total
1	99	99,575	1	0,425	100
2	100	98,846	0	1,154	100
3	96	97,897	4	2,103	100
4	96	96,624	4	3,376	100
5	94	94,649	6	5,351	100
6	90	91,804	10	8,196	100
7	86	87,553	14	12,447	100
8	84	79,563	16	20,437	100
9	63	65,747	37	34,253	100
10	33	35,396	67	64,604	100
Total	841	847,654	159	152,346	1.000

Más allá de que p es mucho mayor que 0,05 (no hay una discrepancia *significativa*), la tabla anterior permite observar que el número esperado de muertos es muy similar al esperado (159 y 152) y que las frecuencias observadas y esperadas son ciertamente muy similares en la atomización que hace el test de Hosmer Lemeshow, el modelo queda claramente validado. Siendo así, se pueden unir las bases para hacer un ajuste final.

Al trabajar con la hoja UNIDO, que contiene 2000 quemados, se obtiene:

Estimación:

Frecuencias de la variable dependiente:

Valor	Frecuencia
NO	1.687
SI	313
Total	2.000

Convergencia de la sucesión de estimadores: Sí

-2 ln Verosimilitud inicial: 1.735,281

-2 ln Verosimilitud final: 1.220,619

Cociente de verosimilitudes:

Estadístico R	gl	Valor p
514,662	6	0,000

gl: grados de libertad

Coefficiente de determinación: 0,308

Coefficiente de Cox y Snell: 0,227

Coefficiente de Nagelkerke: 0,391

Coefficientes de cada variable:

Variable	Coefficiente	EE	Wald	Valor p
Constante	-9,316	0,500	-18,639	0,000
EDAD	0,054	0,004	12,600	0,000
Q1	0,229	0,024	9,515	0,000
Q2	0,100	0,022	4,649	0,000
Q3	0,151	0,023	6,487	0,000
DIA	1,361	0,171	7,948	0,000
CAB	1,561	0,158	9,880	0,000

EE: error estándar de los estimadores

Los coeficientes son muy parecidos; pero los errores estándar son claramente menores que en el caso en que se trabajó solo con las primeras 1000 observaciones, algo coherente con el notable aumento del tamaño muestral.

Obsérvese a continuación lo que arroja el test de bondad de ajuste en este caso en que $n=2000$:

Prueba de bondad de ajuste de Hosmer y Lemeshow:

Estadístico χ^2	gl	Valor p
8,335	8	0,401

gl: grados de libertad

Grupo	MUERE=0		MUERE=1		Total
	Frec. Obs.	Frec. Esp.	Frec. Obs.	Frec. Esp.	
1	197	199,084	3	0,916	200
2	198	197,526	2	2,474	200
3	194	195,379	6	4,621	200
4	193	192,635	7	7,365	200
5	187	188,474	13	11,526	200
6	180	182,476	20	17,524	200
7	177	172,789	23	27,211	200
8	164	157,238	36	42,762	200
9	125	128,953	75	71,047	200
10	72	72,446	128	127,554	200
Total	1.687	1.687,000	313	313,000	2.000

En este contexto predictivo, la probabilidad del suceso para un perfil de entrada dado ha de computarse empleando los coeficientes estimados. Por ejemplo, si se quiere saber cuál es la probabilidad de que muere de un paciente, hay que aplicar la fórmula siguiente:

$$P(\text{muere} = 1) = \frac{1}{1 + \exp(-\beta_0 - \beta_1 E - \beta_2 Q1 - \beta_3 Q2 - \beta_4 Q3 - \beta_5 DIA - \beta_6 CAB)}$$

dónde: $\beta_0 = -9,316$ $\beta_1 = 0,054$ $\beta_2 = 0,229$ $\beta_3 = 0,100$ $\beta_4 = 0,151$ $\beta_5 = 1,361$ $\beta_6 = 1,561$.

Si se tratara de un sujeto de 30 años, con 10, 15 y 20% del cuerpo afectado con quemaduras hipodérmicas, epidérmicas e intermedias respectivamente, las cuales no afectan la cabeza y que no es diabético, la fórmula arroja: $P(\text{muere} = 1) = 0,239$.

Las estimaciones de las probabilidades que se obtuvieron al usar la hoja PRED (véase arriba) con ese fin, resultan ser:

Predicción:

Prob. (MUERE=1)	IC (95,0 %)	
0,003	0,002	0,005
0,005	0,003	0,008
0,015	0,010	0,023
0,065	0,041	0,094
0,239	0,144	0,360
0,550	0,382	0,698
0,854	0,757	0,918
0,860	0,764	0,923

Obsérvese que Epidat 4 no solo calcula la probabilidad de muerte sino también los intervalos de confianza correspondientes. Por ejemplo, para el quinto sujeto, dicha probabilidad es, en efecto, igual a 24% (0,239) y ella se halla entre 15 y 36% con confiabilidad del 95%. NOTA: si el usuario reproduce este proceso obtendrá intervalos ligeramente diferentes debido a que la estimación se realiza mediante la técnica *bootstrap* y en cada caso las 1.000 submuestras que EPIDAT elige para llevarla adelante serán diferentes.

Ejemplo 2: Influencia de un régimen de atención de cuidados de enfermería sobre recuperación de pacientes con fractura de cadera.

Se estudia la infección hospitalaria posquirúrgica en pacientes operados de la cadera. Se desea evaluar la eficacia de un nuevo régimen técnico-organizativo de los cuidados de enfermería que se dispensan a estos pacientes.

El resultado se mide a través de la variable INFEC (INFEC=1 cuando el paciente se infecta a lo largo de la primera semana, INFEC=0 si no se infecta). Se define la variable REGIMEN, de naturaleza dicotómica, que vale 0 si el sujeto estuvo ingresado bajo el nuevo régimen y 1 en caso de que haya estado atendido bajo el régimen convencional.

Se han estudiado 80 pacientes de diferentes edades, 36 de los cuales se han ubicado en el régimen experimental y 44 en el régimen convencional. La expectativa, claro está, es que el nuevo régimen sea mejor y, por tanto, que haya menos casos de infección en este último que en el precedente. Los resultados se recogen en la Tabla 2.

Tabla 2. Distribución de pacientes según régimen de atención enfermera y condición respecto de la infección.

Régimen	Infección	
	Sí (1)	No (0)
Convencional (1)	37	7
Experimental (0)	22	14

OR=3,36

Si a partir de los datos brutos se estima el efecto del régimen de los cuidados de enfermería sobre el hecho de desarrollar una infección, el *odds ratio* resultante es de 3,36 (procedente de computar la llamada *razón de productos cruzados* $[14 \times 37] / [7 \times 22]$).

Considérese, además, que se quiere evaluar si la edad del paciente (se nombrará EDAD a esta variable) constituye una variable de confusión en la relación que pudiera existir entre el régimen organizativo y el hecho de desarrollar una infección.

Está claro que la variable EDAD cumple con los tres criterios convencionalmente admitidos [10] para ser considerada como variable de confusión. Primero, el riesgo de infección aumenta con la edad. Segundo la proporción de pacientes mayores de 40 años es mayor en el grupo que recibió el régimen de atención convencional. Por último, el supuesto de que el efecto protector del régimen experimental sobre el hecho de desarrollar una infección se produzca “a través” de la edad carece de fundamento.

Para valorarlo, los datos se dividen en dos categorías de edad (menores o iguales, o mayores de 40 años, GRUPO=0 y GRUPO=1, respectivamente, lo que produce la configuración que recoge la Tabla 3. Los estimados del *odds ratio* en las dos categorías son de 2,77 y 2,44 respectivamente.

Tabla 3. Distribución de pacientes según régimen de atención enfermera, condición respecto de la infección y grupo de edad.

		Infección		
		Sí (1)	No (0)	
Grupo (1) Edad ≤ 40	Régimen convencional (1)	15	5	OR₁=2,77
	Régimen experimental (0)	13	12	
Grupo (0) Edad > 40	Régimen convencional (1)	22	2	OR₂=2,44
	Régimen experimental (0)	9	2	

Un método usual para valorar una confusión consiste en comparar de forma directa el estimado bruto del efecto y el estimado de éste una vez controlado el presunto factor de confusión. Para ello se debe obtener una estimación del efecto global a partir de los datos estratificados, mediante una media ponderada de las estimaciones de los efectos por estrato.

Retomando nuevamente el ejemplo, ¿será posible que el *odds ratio* total de 3,36 refleje, en alguna dimensión, el efecto confusor que pudiera tener la edad en la relación entre el régimen de atención de enfermería y la infección?

Dentro de cada categoría o estrato formado por los dos grupos de edad (40 o menos y mayores de 40) se puede calcular el *odds ratio* como única medida de la asociación entre el régimen y la infección. Una medida única global se obtiene, como se ha dicho, mediante un promedio ponderado de los *odds ratio* dentro de los estratos. Esto es exactamente lo que provee el *odds ratio* de Mantel Haenszel que, en este caso, como puede corroborarse a través del análisis de tablas 2x2 estratificadas, arroja el valor 2,68.

Al usar el submódulo de regresión logística en esta situación hay que preparar una hoja en Excel, que contenga una tabla de contingencia de 3 entradas con 8 celdas, para que el programa la lea automáticamente según la siguiente estructura:

INFEC	REGIMEN	GRUPO	FREQ
0	0	0	12
0	0	1	2
0	1	0	5
0	1	1	2
1	0	0	13
1	0	1	9
1	1	0	15
1	1	1	22

El archivo CADERA.xls que se incluye en Epidat 4 contiene en su primera hoja (CADERA-GRUPO) la tabla arriba expuesta. Al emplear el programa, el usuario puede elegir cuántas y cuáles variables independientes incorporar al modelo. A continuación se exponen los resultados que se obtienen cuando se pone una sola variable (REGIMEN), y luego los que se producen cuando se adiciona la variable GRUPO.

Caso en que solo se incluye la variable REGIMEN como independiente:

Coefficientes de cada variable:				
Variable	Coefficiente	EE	Wald	Valor p
Constante	0,452	0,342	1,322	0,186
REGIMEN	1,213	0,536	2,265	0,024
EE: error estándar de los estimadores				
Odds Ratio (OR) de cada variable:				
Variable	OR	IC (95,0 %)		
REGIMEN	3,364	1,178	9,608	

Obsérvese que la estimación global del OR asociado al régimen de cuidados es la misma: 3,36 (es el logaritmo natural de 1,213).

Caso en que se incluyen REGIMEN y GRUPO como variables independientes:

Coefficientes de cada variable:

Variable	Coefficiente	EE	Wald	Valor p
Constante	0,093	0,380	0,244	0,807
REGIMEN	0,985	0,557	1,768	0,077
GRUPO	1,364	0,628	2,171	0,030

EE: error estándar de los estimadores

Odds Ratio (OR) de cada variable:

Variable	OR	IC (95,0 %)	
REGIMEN	2,678	0,898	7,983
GRUPO	3,912	1,141	13,405

En este ejemplo, se “controla” el efecto del grupo de edad. La estimación del OR pasa a ser 2,68 (lo mismo que arrojaría la estratificación de Mantel Haenszel).

Ahora bien, el manejo que se ha hecho ha sido a través de datos tabulados. Sin embargo, si tenemos en cuenta que se conocen las edades individuales de todos los participantes y no solo la composición por grupos, el “control” de la edad puede realizarse incorporando esta edad real al modelo en lugar de usar la opción de datos tabulados. Usando la segunda hoja de la base CADERA.XLS, llamada CADERA-EDAD, se obtiene lo siguiente:

Coefficientes de cada variable:

Variable	Coefficiente	EE	Wald	Valor p
Constante	-0,939	0,776	-1,210	0,226
REGIMEN	0,732	0,576	1,271	0,204
EDAD	0,043	0,022	1,967	0,049

EE: error estándar de los estimadores

Odds Ratio (OR) de cada variable:

Variable	OR	IC (95,0 %)	
REGIMEN	2,080	0,672	6,437
EDAD	1,044	1,000	1,090

Nuevamente, se ha “controlado” el efecto de la edad y ahora el OR pasa a ser 2,08. Esta estimación, mucho más refinada (sin la pérdida de información que supuso considerar la edad a nivel dicotómico), sería la más adecuada en este caso en que se cuenta con datos de edad individuales.

Este ejemplo pone de manifiesto que la valoración sobre el posible papel confusor de un factor se desarrolla de manera ágil. Basta correr el modelo con y sin el factor y comparar los coeficientes de la variable independiente. En el ejemplo de los operados de la cadera, se compara 3,36 con 2,08 lo cual permite pensar que sí hay efecto confusor. Sin embargo, lo

verdaderamente relevante es que el REGIMEN de atención mantiene (aunque disminuido) su condición de factor influyente en la disminución de las infecciones.

Ejemplo 3: Prevalencias de positividad a un anticuerpo.

Supóngase que se quiere modelar (caracterizar epidemiológicamente) el modo en que se distribuye cierto virus según 4 zonas. Se considera la variable VIRUS (variable de respuesta: SI y NO) y la variable ZONA (NORTE, SUR, ESTE y OESTE). Estudiados 5.597 sujetos, la distribución según zonas y presencia o no del virus, fue la siguiente:

VIRUS	ZONA	FRECUENCIA
NO	NORTE	909
NO	SUR	1.486
NO	ESTE	99
NO	OESTE	526
SI	NORTE	238
SI	SUR	1.561
SI	ESTE	172
SI	OESTE	606

Es fácil convencerse de que las tasas de prevalencia (expresadas como una fracción y con 3 decimales) son las que aparecen en la Tabla 4.

Tabla 4. Prevalencias estimadas de positividad al virus para las diferentes zonas geográficas.

Zona	Tamaño muestral	Número de positivos	Tasa de prevalencia
Este	271	172	0,635
Norte	1147	238	0,208
Oeste	1132	606	0,535
Sur	3047	1561	0,512

En este punto, y solo a título ilustrativo, resulta interesante encarar esta tarea a través de la RL.

El archivo VIRUS.xls, contiene una hoja llamada ZONA con una tabla de contingencia con los datos de los 5.597 sujetos que constituyen la muestra. Usando la alternativa de Tablas de Frecuencia y declarando la variable ZONA como categórica, Epidat 4.0 crea las siguientes tres variables dummy:

	ZONA1	ZONA2	ZONA3
Este	0	0	0
Norte	1	0	0
Oeste	0	1	0
Sur	0	0	1

Epidat 4 ordena alfabéticamente las categorías y toma la primera como “referencia” (todas las variables dummy valen 0) y de ahí en adelante sigue asignando el 1 y los 0 en ese mismo orden, como se ve en la tabla anterior. Con estos datos se genera el siguiente modelo:

Coefficientes de cada variable:

Variable	Coefficiente	EE	Wald	Valor p
Constante	0,552	0,126	4,379	0,000
ZONA1	-1,892	0,146	-12,992	0,000
ZONA2	-0,411	0,140	-2,944	0,003
ZONA3	-0,503	0,131	-3,833	0,000

EE: error estándar de los estimadores

Si ahora aplicamos la función logística:

$$P(\text{Virus}=1) = \frac{1}{1 + \exp(-\beta_0 - \beta_1 \text{ZONA1} - \beta_2 \text{ZONA2} - \beta_3 \text{ZONA3})}$$

a cada uno de los conjuntos de variables dummy (es decir, para cada zona) obtenemos casi exactamente los mismos valores para las tasas de prevalencia que había arrojado el simple cómputo de la fracción de positivos (Tabla 3) entre sujetos de la muestra en cada zona.

Por ejemplo, para el NORTE (ZONA1=1; ZONA2=0; ZONA3=0), se tiene:

$$P(\text{Virus}=1) = \frac{1}{1 + \exp(-\beta_0 - \beta_1 \text{ZONA1})} = \frac{1}{1 + \exp(-\beta_0 - \beta_1)} = \frac{1}{1 + \exp(-0,552 + 1,892)} = 0,208$$

Como nota final, se llama la atención acerca de cómo en este caso la bondad de ajuste es perfecta:

Prueba de bondad de ajuste de Hosmer y Lemeshow:

Estadístico χ^2	gl	Valor p
0,000	2	1,000

gl: grados de libertad

Grupo	VIRUS=0		VIRUS=1		Total
	Frec. Obs.	Frec. Esp.	Frec. Obs.	Frec. Esp.	
1	909	909,000	238	238,000	1.147
2	1.486	1.486,000	1.561	1.561,000	3.047
3	526	526,000	606	606,000	1.132
4	99	99,000	172	172,000	271
Total	3.020	3.020,000	2.577	2.577,000	5.597

Un comentario interesante en este caso es el siguiente. Para aplicar la predicción en este caso, se puede usar la hoja VIRUS-PRED, la cual meramente contiene los 4 perfiles posibles. El resultado es:

Prob. (VIRUS=1)	Límite Inf.	Límite Sup.
0,635	0,578	0,695
0,207	0,183	0,230
0,535	0,506	0,564
0,512	0,493	0,529

La comparación de la primera columna de esta tabla con la última de la Tabla 4 arroja lo esperado: la RL estima las tasas de la misma manera que cuando se hace la mera división del número de positivos entre el tamaño muestral en cada zona. Pero resulta interesante, y fácil de corroborar por el lector, que los intervalos de confianza -construidos a través de la técnica bootstrap- coinciden casi exactamente con los que se obtendrían si se aplica la fórmula clásica para la estimación de un porcentaje: $p \pm 1,96\sqrt{p(1-p)/n}$:

Zona	Tasa de prevalencia	Intervalo 95%	
Este	0,6347	0,577	0,692
Norte	0,2075	0,184	0,231
Oeste	0,5353	0,506	0,564
Sur	0,5123	0,495	0,530

Ejemplo 4: Influencia del tipo de contrato en accidentes laborales.

Se tiene la hipótesis de que aquellos trabajadores que laboran bajo un contrato *indefinido* tienden a padecer menos accidentes que aquellos cuyo contrato es de tipo *temporal*. Tal conjetura se basa en la idea de que quienes están en este último caso no exigen (por temor a no ser recontratados) que se cumplan las reglas de seguridad establecidas.

Con el propósito de evaluar dicha hipótesis, se realiza un estudio de cohortes con 6.400 sujetos, 3.040 tienen contratos temporales y 3.360 los tienen indefinidos y para todos los cuales se observó si tuvieron o no un accidente en el curso de los siguientes 5 años posteriores al inicio del estudio. Los resultados fueron:

Accidente	Contrato	
	Temporal	Indefinido
Con accidente (1)	a=1.442	c=534
Sin accidente (0)	b=1.598	d=2.826

Obsérvese que el OR es mucho mayor que 1, casi igual a 5. Eso hace pensar que aproximadamente es 5 veces más peligroso tener un contrato temporal que uno indefinido:

$$OR = \frac{(a)(b)}{(c)(d)} = \frac{(1.442)(2.826)}{(1.598)(534)} = 4,78$$

Si se quiere hacer una prueba de significación, se obtendrá:

$$\chi^2_{obs} = \frac{n(ad-bc)^2}{(b+d)(a+c)(a+b)(c+d)} = \frac{6.400(1.442 \times 2.826 - 1.598 \times 534)^2}{(4.424)(1.976)(3.360)(3.040)} = 744,0$$

al cual se asocia un valor de $p=0,000$, de modo que la asociación sería altamente significativa.

Ahora bien, ¿puede considerarse probada la hipótesis de causalidad? Para avanzar en esa línea, habría que valorar si existen variables confusoras que puedan “controlarse”. Un análisis del problema conduce a pensar que verosíblemente las personas con más experiencia deberían tener menos accidentes y a la vez ser las que con más frecuencia tendrían contratos indefinidos. Algo similar ocurriría con la categoría laboral (por ejemplo, un arquitecto debe tener menos propensión a accidentarse que un albañil y simultáneamente sería más probable que este último tuviera un contrato temporal que el primero). Esto ocurriría análogamente con la edad y con la escolaridad.

Obsérvese, por ejemplo, cómo las tasas (%) de accidentados van disminuyendo a medida que aumenta la escolaridad en la muestra:

Escolaridad	Accidentados	Total	%
ANALFABETO	1.177	1.392	84,6
PRIMARIO	272	576	47,2
SECUNDARIO	224	816	27,5
MEDIO	155	1.472	10,5
SUPERIOR	148	2.144	6,9
Total	1.976	6.400	30,9

La pregunta relevante sería entonces: ¿la probabilidad de que se produzca (o no) un accidente es mayor para los temporales que para los indefinidos, independientemente del tipo de trabajo, de los años de experiencia, de la escolaridad y de la edad?

A través de la RL, el hecho de que un sujeto tenga o no un accidente se pondrá en función de todas estas variables, para poder controlarlas todas a la vez, aparte, claro está, de la variable en estudio (el tipo de contrato). Las variables del modelo serían:

- **Tipo de contrato** CONTRATO (x_1), dicotómica (1.TEMPORAL, 2.INDEFINIDO).
- **Tiempo de experiencia** EXPER (x_2), cuantitativa (AÑOS).
- **Edad del sujeto** EDAD (x_3), cuantitativa (AÑOS).
- **Categoría laboral** CATEG (x_4), ordinal (codificada como 1=MANUAL, 2=TÉCNICO, 3=PROFESIONAL).
- **Máxima escolaridad alcanzada** ESCO (x_5), ordinal (codificada como 1=ANALFABETO, 2=PRIMARIO, 3=SECUNDARIO, 4=MEDIO, 5=SUPERIOR).

El libro ACCIDENTES.xls contiene todos estos datos para 6.400 individuos de la cohorte. Los primeros 10 son los siguientes:

TRABAJADOR	ACCIDENTE	CONTRATO	EDAD	CATEG	EXPER	ESCO
1	0	1.INDEFINIDO	56	1	12	5
2	0	2.TEMPORAL	42	1	8	3
3	0	2.TEMPORAL	51	1	17	5
4	0	1.INDEFINIDO	61	1	17	5
5	0	1.INDEFINIDO	57	1	15	4
6	0	1.INDEFINIDO	83	1	21	5
7	0	1.INDEFINIDO	78	1	20	5
8	0	1.INDEFINIDO	64	1	23	2
9	0	1.INDEFINIDO	73	1	26	4
10	0	1.INDEFINIDO	49	1	7	4

Si se corre el modelo incorporando solo el contrato como variable independiente, se obtiene la misma estimación del OR que la arriba obtenida:

Estimación:

Frecuencias de la variable dependiente:

Valor	Frecuencia
0	4.424
1	1.976
Total	6.400

Coefficientes de cada variable:

Variable	Coefficiente	EE	Wald	Valor p
Constante	-1,666	0,047	-35,312	0,000
CONTRATO1	1,563	0,060	26,257	0,000

EE: error estándar de los estimadores

Odds Ratio (OR) de cada variable:

Variable	OR	IC (95,0 %)	
CONTRATO1	4,776	4,249	5,367

Si se incluyen todos, el resultado es como sigue:

Estimación:

Coeficiente de determinación: 0,743
 Coeficiente de Cox y Snell: 0,574
 Coeficiente de Nagelkerke: 0,808

Coeficientes de cada variable:

Variable	Coeficiente	EE	Wald	Valor p
Constante	6,878	0,312	22,049	0,000
EDAD	-0,032	0,005	-7,059	0,000
CATEG	0,588	0,082	7,131	0,000
EXPER	-0,514	0,018	-28,378	0,000
ESCO	-1,102	0,041	-26,570	0,000
CONTRATO1	0,980	0,129	7,582	0,000

EE: error estándar de los estimadores

Odds Ratio (OR) de cada variable:

Variable	OR	IC (95,0 %)	
EDAD	0,969	0,960	0,977
CATEG	1,800	1,532	2,116
EXPER	0,598	0,577	0,620
ESCO	0,332	0,306	0,360
CONTRATO1	2,663	2,068	3,431

Se aprecia que el valor de los coeficientes de determinación, Snell y Nagelkerke son altos. Pero el usuario debe concentrar su atención en la última línea (las restantes variables no tienen interés, en el sentido de que la pregunta solo concierne al contrato y las demás variables se han incluido con la única finalidad de controlarlas). Y allí se ve que el OR pasa a ser 2,63. Si bien es menor que el 4,77, sigue siendo alto (en el “peor” de los casos la probabilidad de accidente entre temporales sería 2,03 veces mayor que entre indefinidos y podría llegar a ser 3,4 veces mayor).

Ahora bien, en este caso (por ser un estudio de cohortes) podría estimarse la probabilidad de que un sujeto con determinado perfil sufra un accidente. En la hoja PRED-ACC aparecen 36 perfiles (las posibles combinaciones, para cada tipo de contrato, de 25, 35 y 45 años de edad, 5 y 15 años de experiencia, categoría laboral MANUAL, TÉCNICO y PROFESIONAL y tres escolaridades (ANALFABETO, SECUNDARIO y SUPERIOR). Si se pide que se estimen las probabilidades de accidentarse en los próximos 5 años de sujetos con esos perfiles, se obtiene lo siguiente (transcrito desde el archivo al cual fueron enviados los resultados, luego de elegir tal opción y habiendo reducido las cifras decimales a tres):

CONTRATO	EDAD	CATEG	EXPER	ESCO	Prob. (ACCIDENTE=1)	Límite Inf.	Límite Sup.
1.INDEFINIDO	25	1	5	1	0,952	0,938	0,965
1.INDEFINIDO	35	1	5	3	0,616	0,566	0,666
1.INDEFINIDO	45	1	5	5	0,114	0,088	0,143
1.INDEFINIDO	25	2	5	1	0,973	0,964	0,981
1.INDEFINIDO	35	2	5	3	0,743	0,703	0,780
1.INDEFINIDO	45	2	5	5	0,188	0,155	0,225
1.INDEFINIDO	25	3	5	1	0,985	0,978	0,990
1.INDEFINIDO	35	3	5	3	0,839	0,797	0,877
1.INDEFINIDO	45	3	5	5	0,294	0,237	0,354
1.INDEFINIDO	25	1	15	1	0,105	0,074	0,146
1.INDEFINIDO	35	1	15	3	0,009	0,006	0,014
1.INDEFINIDO	45	1	15	5	0,001	0,000	0,001
1.INDEFINIDO	25	2	15	1	0,175	0,124	0,236
1.INDEFINIDO	35	2	15	3	0,017	0,011	0,024
1.INDEFINIDO	45	2	15	5	0,001	0,001	0,002
1.INDEFINIDO	25	3	15	1	0,276	0,195	0,375
1.INDEFINIDO	35	3	15	3	0,030	0,019	0,045
1.INDEFINIDO	45	3	15	5	0,002	0,001	0,004
2.TEMPORAL	25	1	5	1	0,982	0,976	0,986
2.TEMPORAL	35	1	5	3	0,810	0,780	0,837
2.TEMPORAL	45	1	5	5	0,255	0,210	0,300
2.TEMPORAL	25	2	5	1	0,990	0,986	0,993
2.TEMPORAL	35	2	5	3	0,885	0,860	0,906
2.TEMPORAL	45	2	5	5	0,381	0,329	0,433
2.TEMPORAL	25	3	5	1	0,994	0,991	0,996
2.TEMPORAL	35	3	5	3	0,933	0,908	0,951
2.TEMPORAL	45	3	5	5	0,526	0,446	0,601
2.TEMPORAL	25	1	15	1	0,239	0,184	0,306
2.TEMPORAL	35	1	15	3	0,024	0,017	0,034
2.TEMPORAL	45	1	15	5	0,002	0,001	0,003
2.TEMPORAL	25	2	15	1	0,361	0,281	0,450
2.TEMPORAL	35	2	15	3	0,043	0,031	0,059
2.TEMPORAL	45	2	15	5	0,004	0,002	0,005
2.TEMPORAL	25	3	15	1	0,504	0,391	0,617
2.TEMPORAL	35	3	15	3	0,075	0,049	0,109
2.TEMPORAL	45	3	15	5	0,006	0,004	0,010

Ejemplo 5: Diagnóstico de depresión mayor en ancianos.

Supóngase que se quiere construir un instrumento que permita refinar el diagnóstico de depresión en ancianos (mayores de 65 años) que acuden a una consulta de psiquiatría de cierto hospital urbano. Se cuenta con un test de evaluación novedoso que tiene

SENSIBILIDAD y ESPECIFICIDAD iguales a 0,9. Se tienen las historias clínicas de 189 personas donde se ha registrado el diagnóstico. A los efectos de este análisis interesa la variable DEPRES (0- No deprimido, 1- Deprimido) y que la probabilidad de estar deprimido se quiere poner en función de $r=4$ variables, a saber:

- ANTEC, variable nominal con $k=2$ categorías: Tiene, No tiene.
- GÉNERO, variable nominal con $k=2$ categorías: Hombre, Mujer.
- HIJOS, variable numérica (entero positivo).
- EDAD, variable numérica medida en años.

El archivo DEPRES.xls contiene una hoja, llamada DEPRES, con los datos de este ejemplo. Al aplicar el programa a los datos precedentes se obtiene:

Cociente de verosimilitudes:

Estadístico R	gl	Valor p
195,329	4	0,000

gl: grados de libertad

Coeficiente de determinación: 0,788

Coeficiente de Cox y Snell: 0,644

Coeficiente de Nagelkerke: 0,867

Coeficientes de cada variable:

Variable	Coeficiente	EE	Wald	Valor p
Constante	-51,557	10,503	-4,909	0,000
HIJOS	-1,086	0,262	-4,146	0,000
EDAD	0,722	0,149	4,860	0,000
ANTEC1	3,473	0,941	3,690	0,000
GÉNERO1	-0,183	0,723	-0,252	0,801

EE: error estándar de los estimadores

Odds Ratio (OR) de cada variable:

Variable	OR	IC (95,0 %)	
HIJOS	0,338	0,202	0,564
EDAD	2,059	1,539	2,755
ANTEC1	32,219	5,094	203,799
GÉNERO1	0,833	0,202	3,439

De los datos se deduce que cuanto más hijos y menos edad, menos probable es la depresión. Esta es particularmente más acusada en quienes tienen antecedentes (el riesgo sería 32 veces mayor que entre quienes no los tienen), pero el sexo no arroja significación alguna. En este ejemplo, el ajuste es francamente bueno, lo cual se aprecia comparando frecuencias observadas y esperadas y se confirma al obtener una p muy superior a los niveles admitidos convencionalmente para declarar significación. El área bajo la curva ROC en este caso es considerablemente alta, hecho coherente con que las 4 variables incorporadas consiguen una reducción significativa de la lejanía.

En la hoja DEPRE-PRED-SE se han colocado los siguientes 16 perfiles de interés:

ANTEC	GÉNERO	HIJOS	EDAD
Tiene	Hombre	0	65
Tiene	Hombre	0	75
Tiene	Mujer	0	65
Tiene	Mujer	0	75
Tiene	Hombre	3	65
Tiene	Hombre	3	75
Tiene	Mujer	3	65
Tiene	Mujer	3	75
No tiene	Hombre	0	65
No tiene	Hombre	0	75
No tiene	Mujer	0	65
No tiene	Mujer	0	75
No tiene	Hombre	3	65
No tiene	Hombre	3	75
No tiene	Mujer	3	65
No tiene	Mujer	3	75

Al pedir las estimaciones de las probabilidades respectivas y que se obtengan los valores predictivos, se obtiene lo siguiente (transcrito desde el archivo al cual fueron enviados los resultados, luego de elegir tal opción y habiendo reducido las cifras decimales a tres):

Prob. (DEPRE=1)	Límite inferior	Límite superior	VPN	VPN inferior	VPN superior	VPP	VPP inferior	VPP superior
0,242	0,008	0,705	0,034	0,001	0,210	0,741	0,064	0,956
0,998	0,991	1,000	0,980	0,921	1,000	1,000	0,999	1,000
0,210	0,010	0,744	0,029	0,001	0,244	0,705	0,081	0,963
0,997	0,989	1,000	0,976	0,905	1,000	1,000	0,999	1,000
0,012	0,000	0,038	0,001	0,000	0,004	0,099	0,002	0,261
0,944	0,846	0,994	0,651	0,379	0,950	0,993	0,980	0,999
0,010	0,000	0,042	0,001	0,000	0,005	0,084	0,002	0,284
0,933	0,727	0,996	0,609	0,228	0,964	0,992	0,960	1,000
0,010	0,000	0,034	0,001	0,000	0,004	0,082	0,002	0,241
0,931	0,845	0,993	0,601	0,378	0,943	0,992	0,980	0,999
0,008	0,000	0,024	0,001	0,000	0,003	0,069	0,002	0,180
0,919	0,819	0,991	0,556	0,334	0,925	0,990	0,976	0,999
0,000	0,000	0,001	0,000	0,000	0,000	0,003	0,000	0,013
0,343	0,039	0,688	0,055	0,004	0,197	0,824	0,268	0,952
0,000	0,000	0,001	0,000	0,000	0,000	0,003	0,000	0,011
0,303	0,025	0,681	0,046	0,003	0,192	0,796	0,188	0,951

Por ejemplo (en negritas en la tabla precedente), una mujer con antecedentes, de 75 años y con 3 hijos tendría una probabilidad de depresión igual a 0,933 (la cual se halla entre 0,727 y

0,996 con confiabilidad del 95%). Si la prueba diera negativo, esa probabilidad bajaría a 0,609 y si diera positivo, subiría a 0,992. Estos valores predictivos tienen sus respectivos intervalos (0,228 – 0,964, en el primer caso y 0,960 – 1,000 en el segundo).

Nota: Algunos de los ejemplos expuestos se basan en ilustraciones presentes en el libro “Regresión Logística” de Silva y Barroso [11], donde el usuario de Epidat hallará muchos más detalles conceptuales y prácticos.

Bibliografía

1. Cornfield J, Gordon T, Smith WN. Quantal response curves for experimentally uncontrolled variables. *Bulletin of the International Statistical Institute*. 1961;38:97-115.
2. Walker SH, Duncan DB. Estimation of the probability of an event as a function of several independent variables. *Biometrika*. 1967;54:167-79.
3. Silva LC, Pérez C, Cuellar I. Uso de la estadística en la investigación de salud contemporánea. *Gac Sanit*. 1994;9(48):189-95.
4. Levy PS, Stolte K. Statistical methods in public health and epidemiology: a look at the recent past and projections for the next decade. *Stat Methods Med Res*. 2000;9:41-55.
5. Jones RH. Probability estimation using a multinomial logistic function. *Journal of Statistical and Computer Simulation*. 1975;3:315-29.
6. Silva LC. Excursión a la regresión logística en ciencias de la salud. Madrid: Díaz de Santos; 1995.
7. Mittlböck M, Schemper M. Explained variation for logistic regression. *Stat Med*. 1996;15:1987-97.
8. Hosmer DW Jr, Lemeshow S. *Applied Logistic Regression*. New York: John Wiley & Sons; 1989.
9. Silva LC. Los laberintos de la investigación biomédica. En defensa de la racionalidad para la ciencia en el Siglo XXI. Madrid: Díaz de Santos; 2010.
10. De Irala J, Martínez MA, Guillén F. ¿Qué es una variable de confusión? *Med Clin (Barc)*. 2001;117:377-85.
11. Silva LC, Barroso J. *Regresión Logística*. Cuaderno 27. Madrid: La Muralla; 2004.

Anexo 1: Novedades del módulo de regresión logística

Novedades de la versión 4.1 con respecto a la versión 3.1:

- La entrada de datos solo se puede realizar de forma automática, y pueden cargarse datos resumidos, como en la versión previa, y también datos individuales.
- En el test de bondad de ajuste de Hosmer y Lemeshow se cambia el método para definir los grupos.
- El gráfico de la curva ROC se puede personalizar mediante el editor de gráficos.
- Se ofrece la posibilidad de validar el modelo estimado tanto con una muestra diferente como con la utilizada para la estimación.
- Se incluye una opción para estimar las probabilidades predichas por el modelo para un conjunto de perfiles que se leen de un archivo diferente al utilizado para la estimación. Los resultados de la predicción se guardan en un archivo con intervalos de confianza obtenidos por el método bootstrap.
- En la opción de predicción es posible calcular valores predictivos, también con intervalos de confianza bootstrap, a partir de las probabilidades predichas y de unos valores de sensibilidad y especificidad indicados por el usuario.

Anexo 2: Fórmulas del módulo de regresión logística

Esquema del módulo

1. Regresión logística

1.- REGRESIÓN LOGÍSTICA

Si $X_1, X_2, \dots, X_r$ son r variables independientes e Y es una variable con respuesta dicotómica 0-1, entonces el modelo múltiple de regresión logística está dado por:

$$P(Y = 1) = \frac{1}{1 + \exp(-\beta_0 - \beta_1 X_1 - \dots - \beta_r X_r)}$$

donde $\exp(\cdot)$ representa la función exponencial. El modelo se estima por el método de máxima verosimilitud utilizando el algoritmo de Newton Raphson [Jones (1975)], y como resultado se obtienen los coeficientes estimados $\hat{\beta}_k$ con sus varianzas $\hat{V}(\hat{\beta}_k)$, $k=0, 2, \dots, r$.

Lejanías [Silva (1995, p. 43-44, 213)]:

Inicial: $-2 \ln(V_I)$

Final: $-2 \ln(V_F)$

Cociente de verosimilitudes [Silva (1995, p. 43-44)]:

Estadístico para contrastar $H_0: \beta_1 = \beta_2 = \dots = \beta_r = 0$:

$R = 2(\ln V_F - \ln V_I)$, que sigue una distribución χ^2 con r grados de libertad.

Coefficientes de calidad del ajuste:

Coefficiente de determinación [Mittlböck & Schemper (1996)]:

$$R^2 = \frac{\left(\sum_{i=1}^n (y_i - \bar{p})(\hat{p}_i - \bar{p}) \right)^2}{\sum_{i=1}^n (y_i - \bar{p})^2 \sum_{i=1}^n (\hat{p}_i - \bar{p})^2}$$

Coefficiente de Cox y Snell [Cox & Snell (1989)]:

$$R_{CS}^2 = 1 - \left[\frac{\ln V_I}{\ln V_F} \right]^{\frac{2}{n}}$$

Coeficiente de Nagelkerke [Nagelkerke (1991)]:

$$R_N^2 = \frac{R_{CS}^2}{1 - (\ln V_I)^{\frac{2}{n}}}$$

Dónde:

- $V_I = \exp \left[n_0 \ln \left(\frac{n_0}{n} \right) + n_1 \ln \left(\frac{n_1}{n} \right) \right]$ es la verosimilitud inicial,
- $V_F = \prod_{i=1}^n \hat{p}_i^{y_i} (1 - \hat{p}_i)^{1-y_i}$ es la verosimilitud final,
- n_0 es el número de observaciones con $Y=0$,
- n_1 es el número de observaciones con $Y=1$,
- $n=n_0+n_1$ es el número total de observaciones,
- r es el número de variables explicativas,
- y_i es el valor de la variable Y en la i -ésima observación, $i=1, \dots, n$,
- $\hat{p}_i$ es la probabilidad predicha por el modelo final para la i -ésima observación, $i=1, \dots, n$,
- $\bar{p}$ es la proporción de observaciones con $Y=1$.

Test de Wald [Silva (1995, p.45-46)]:

Estadístico para contrastar $H_0: \beta_k=0$ frente a $H_1: \beta_k \neq 0$, $k=0, 1, \dots, r$:

$$z = \frac{\hat{\beta}_k}{EE(\hat{\beta}_k)} \approx N(0,1)$$

Odds ratio e intervalo de confianza [Silva & Barroso (2004)]:

Odds ratio de la variable k , $k=1, 2, \dots, r$:

$$OR_k = \exp(\hat{\beta}_k)$$

Intervalo de confianza para el odds ratio con nivel de confianza $(1-\alpha)\%$:

$$\left(\exp \left(\hat{\beta}_k - z_{1-\alpha/2} EE(\hat{\beta}_k) \right), \exp \left(\hat{\beta}_k + z_{1-\alpha/2} EE(\hat{\beta}_k) \right) \right)$$

Dónde:

- $EE(\hat{\beta}_k) = \sqrt{\hat{V}(\hat{\beta}_k)}$ es el error estándar de $\hat{\beta}_k$, $k=0,\dots,r$,
- $z_{1-\alpha/2}$ es el percentil de la distribución normal estándar, $N(0,1)$, que deja a la izquierda una cola de probabilidad $1 - \frac{\alpha}{2}$,
- $1-\alpha$ es el nivel de confianza.

Test de bondad de ajuste de Hosmer y Lemeshow [Lemeshow & Hosmer (1982)]:

Estadístico de Hosmer y Lemeshow:

$$\chi^2 = \sum_{i=1}^g \frac{(O_i - E_i)^2}{E_i} + \sum_{i=1}^g \frac{(O_i^* - E_i^*)^2}{E_i^*}, \text{ que sigue una distribución } \chi^2 \text{ con } r \text{ grados de libertad,}$$

Dónde:

- $g \leq 10$ es el número de grupos en que se dividen las n observaciones a partir de las probabilidades predichas por el modelo,
- $O_i = \sum_{j=1}^{n_i} y_j$ es la frecuencia observada de valores iguales a 1 en el i -ésimo grupo,
 $i=1,\dots,g$,
- $O_i^* = n_i - O_i$ es la frecuencia observada de valores iguales a 0 en el i -ésimo grupo,
 $i=1,\dots,g$,
- n_i es el número total de observaciones en el i -ésimo grupo, $i=1,\dots,g$,
- $E_i = \sum_{j=1}^{n_i} \hat{p}_j$ es la frecuencia esperada de valores iguales a 1 en el i -ésimo grupo,
 $i=1,\dots,g$,
- $E_i^* = n_i - E_i$ es la frecuencia esperada de valores iguales a 0 en el i -ésimo grupo,
 $i=1,\dots,g$.

Curva ROC [Silva (1997, p.239)]:

Área bajo la curva ROC:

$$\Delta = \frac{1}{ua} \sum_{i=1}^n \left(u_i A_i + \frac{u_i a_i}{2} \right)$$

Error estándar del área bajo la curva ROC:

$$EE(\Delta) = \sqrt{\frac{1}{ua} \left[\Delta(1-\Delta) + (a-1)(U-\Delta^2) + (n-1)(V-\Delta^2) \right]}$$

Intervalo de confianza para el área bajo la curva ROC con nivel de confianza $(1-\alpha)\%$:

$$\left(\Delta - z_{1-\alpha/2} EE(\Delta), \Delta + z_{1-\alpha/2} EE(\Delta) \right)$$

Dónde:

- m es el número de categorías en que se dividen las n observaciones a partir de las probabilidades predichas por el modelo,
- a_i es el número de observaciones con $Y=1$ en la i-ésima categoría, $i=1, \dots, m$,
- u_i es el número de observaciones con $Y=0$ en la i-ésima categoría, $i=1, \dots, m$,
- $a = \sum_{i=1}^m a_i$ es el número total de observaciones con $Y=1$,
- $u = \sum_{i=1}^m u_i$ es el número total de observaciones con $Y=0$,
- $A_i = a - \sum_{j=1}^i a_j$, $i=1, \dots, m$,
- $U_i = \sum_{j=1}^{i-1} u_j$, $j=2, \dots, m$, y $U_1 = 0$,
- $U = \frac{1}{ua^2} \sum_{i=1}^m u_i \left(A_i^2 + A_i a_i + \frac{a_i^2}{3} \right)$ y $V = \frac{1}{au^2} \sum_{i=1}^m a_i \left(U_i^2 + U_i u_i + \frac{u_i^2}{3} \right)$,
- $z_{1-\alpha/2}$ es el percentil de la distribución normal estándar, $N(0,1)$, que deja a la izquierda una cola de probabilidad $1 - \frac{\alpha}{2}$,
- $1-\alpha$ es el nivel de confianza.

Valores predictivos:

Valor predictivo positivo:

$$VPP = \frac{S\hat{p}_i}{S\hat{p}_i + (1-E)(1-\hat{p}_i)}$$

Valor predictivo negativo:

$$VPN = \frac{(1-S)\hat{p}_i}{(1-S)\hat{p}_i + E(1-\hat{p}_i)}$$

Intervalo de confianza bootstrap para el valor predictivo positivo con nivel de confianza $(1-\alpha)\%$ [Efron & Tibshirani (1993)]:

$$\left(\frac{S\hat{p}_{i,\frac{\alpha}{2}}^*}{S\hat{p}_{i,\frac{\alpha}{2}}^* + (1-E)(1-\hat{p}_{i,\frac{\alpha}{2}}^*)}, \frac{S\hat{p}_{i,1-\frac{\alpha}{2}}^*}{S\hat{p}_{i,1-\frac{\alpha}{2}}^* + (1-E)(1-\hat{p}_{i,1-\frac{\alpha}{2}}^*)} \right)$$

Intervalo de confianza bootstrap para el valor predictivo negativo con nivel de confianza $(1-\alpha)\%$ [Efron & Tibshirani (1993)]:

$$\left(\frac{(1-S)\hat{p}_{i,\frac{\alpha}{2}}^*}{(1-S)\hat{p}_{i,\frac{\alpha}{2}}^* + E(1-\hat{p}_{i,\frac{\alpha}{2}}^*)}, \frac{(1-S)\hat{p}_{i,1-\frac{\alpha}{2}}^*}{(1-S)\hat{p}_{i,1-\frac{\alpha}{2}}^* + E(1-\hat{p}_{i,1-\frac{\alpha}{2}}^*)} \right)$$

Dónde:

- S es la sensibilidad,
- E es la especificidad,
- $\hat{p}_i$ es la probabilidad predicha por el modelo para la i-ésima observación, $i=1, \dots, n$,
- $\hat{p}_{i,\frac{\alpha}{2}}^*$ es el percentil de orden $\frac{\alpha}{2}$ de las $B=1.000$ estimaciones bootstrap $(\hat{p}_i^{*(b)}, b=1, \dots, B)$ de la probabilidad predicha por el modelo, $i=1, \dots, n$,
- $\hat{p}_{i,1-\frac{\alpha}{2}}^*$ es el percentil de orden $1-\frac{\alpha}{2}$ de las $B=1.000$ estimaciones bootstrap $(\hat{p}_i^{*(b)}, b=1, \dots, B)$ de la probabilidad predicha por el modelo, $i=1, \dots, n$,
- $1-\alpha$ es el nivel de confianza.

Bibliografía

- Cox DR, Snell EJ. The analysis of binary data (2nd ed.). London: Chapman and Hall; 1989.
- Efron B, Tibshirani RJ. An introduction to the bootstrap. New York: Chapman & Hall; 1993.
- Jones RH. Probability estimation using a multinomial logistic function. Journal of Statistical and Computer Simulation. 1975;3:315-29.
- Lemeshow S, Hosmer DW Jr. A review of goodness of fit statistics for use in the development of logistic regression models. Am J Epidemiol. 1982;115:92-106.
- Mittlböck M, Schemper M. Explained variation for logistic regression. Stat Med. 1996;15:1987-97.
- Nagelkerke N. A note on a general definition of the coefficient of determination. Biometrika. 1991;78:691-2.
- Silva LC. Excursión a la regresión logística en ciencias de la salud. Madrid: Díaz de Santos; 1995.
- Silva LC. Cultura estadística e investigación científica en ciencias de la salud. Una mirada crítica. Madrid: Díaz de Santos; 1997.
- Silva LC, Barroso J. Regresión Logística. Cuaderno 27. Madrid: La Muralla; 2004.